

Model Validasyonu

Çapraz Doğrulama Yöntemleri ile Genelleme Yeteneği Değerlendirmesi

AI/ML Ekibi
Akıllı Tarım Yönetim Sistemi

Mayıs 2025

1 Yönetici Özeti

Bu rapor, Akıllı Tarım Yönetim Sistemi'nde kullanılan makine öğrenmesi modellerinin genelleme yeteneğini değerlendirmek amacıyla uygulanan çapraz doğrulama (cross-validation) çalışmalarını belgelemektedir. Modellerin yalnızca eğitim verisine değil, gerçek tarla koşullarına da başarıyla uyum sağladığını doğrulamak temel amaçtır.

Genel bulgu olarak 6 modelden 4'ü hedef metrik eşliğini aştı. LSTM ve SVM tabanlı hastalık tespit modeli revize edilmek üzere işaretlendi. Time Series Split yöntemi, zaman bağımlı tüm modellerde veri sızıntısını başarıyla önledi.

2 Çapraz Doğrulama Yöntemleri

Farklı model türleri ve veri yapıları için uygun yöntemler aşağıdaki kriterler çerçevesinde seçilmiştir: veri boyutu, zaman bağımlılığı, sınıf dengesi ve grup bağımsızlığı.

Yöntem	Açıklama	En İyi Kullanım	Fold Sayısı	Hesap Maliyeti
K-Fold CV	Veri k eşit parçaya bölünür; her parça sırayla test seti olarak kullanılır	Dengeli, yeterli veri, genel regresyon/sınıflandırma	k= 5 veya 10	Orta
Stratified K-Fold	Sınıf dağılımı her fold'da korunur; dengesiz veri setleri için kritik	Dengesiz sınıf dağılımı, tarımsal hastalık tespiti	k= 5 veya 10	Orta
Time Series Split	Geçmişten geleceğe kayan pencere; veri sızıntısını önler	Sensör zaman serisi, verim/nem tahmini modelleri	5-10 split	Düşük

Yöntem	Açıklama	En İyi Kullanım	Fold Sayısı	Hesap Maliyeti
Leave-One-Out (LOO)	Her örnek bir kez test seti; küçük veri setlerinde tarafsız tahmin	Küçük arazi parçası veri seti ($N < 100$)	N (tüm örnekler)	Çok Yüksek
Group K-Fold	Aynı grup (arazi/sensör) tek fold'da; bağımsız grup garantisi	Farklı tarla parçaları arasında genelleme testi	$k = 5$	Orta
Nested CV	Dış döngü: test performansı, iç döngü: hiperparametre optimizasyonu	Eş zamanlı model seçimi ve değerlendirme	$5 \times 5 = 25$	Yüksek

2.1 Yöntem Seçim Kriterleri

- **Zaman serisi verisi** (sensör okumaları, verim): Time Series Split – shuffle yasak, kronolojik sıra zorunlu.
- **Dengesiz sınıf** (hastalık tespiti, sulama kararı): Stratified K-Fold – her fold'da sınıf oranı korunur.
- **Tarla bağımsızlığı testi**: Group K-Fold – aynı arazi parçası yalnızca tek fold'da yer alır.
- **Hiperparametre araması ile birlikte**: Nested CV – iyimser bias'ı ortadan kaldırmak için zorunlu.

3 Model Bazlı Validasyon Sonuçları

Her model için seçilen CV yöntemi, elde edilen ortalama skor, fold'lar arası standart sapma ve hedefe göre durum bilgisi aşağıda sunulmaktadır.

Model	CV Yöntemi	Ort. F1 / R^2	Std Sapma	Hedef	Fark	Durum
XGBoost (Sulama)	Stratified 10-Fold	F1: 0.893	± 0.021	$F1 > 0.90$	-0.007	Yakın
Prophet (Verim)	Time Series Split	R^2 : 0.871	± 0.034	$R^2 > 0.85$	+0.021	Geçti
Isolation Forest	K-Fold ($k=5$)	F1: 0.812	± 0.048	$F1 > 0.80$	+0.012	Geçti
Random Forest (Sulama)	K-Fold ($k=10$)	R^2 : 0.856	± 0.029	$R^2 > 0.85$	+0.006	Geçti

Model	CV Yöntemi	Ort. F1 / R^2	Std Sapma	Hedef	Fark	Durum
LSTM (Uzun Dönem)	Time Series Split	R^2 : 0.743	± 0.061	$R^2 > 0.80$	-0.057	Revize
Hastalık Tespit (SVM)	Stratified 5-Fold	F1: 0.778	± 0.055	$F1 > 0.80$	-0.022	Revize

4 Performans Metrikleri ve Eşikler

Model türü ve görev niteliğine göre birincil, ikincil ve yardımcı metrikler belirlenmiştir.

Metrik	Formül / Tanım	Kullanım yosu	Senar- yosu	Hedef Ara- lık	Öncelik
F1 Score	$2 \times (\text{Precision} \times \text{Recall}) / (\text{P} + \text{R})$	Sulama hastalık sınıflandırması	kararı,	> 0.85	Birincil
R²	$1 - \text{SS}_{\text{res}} / \text{SS}_{\text{tot}}$	Verim ve su tüketimi regresyon modelleri		> 0.85	Birincil
MAPE	Ortalama mutlak yüzde hata	Mahsul verim ve fiyat tahmini		$< \%8$	Birincil
ROC-AUC	TPR eğrisi altındaki alan	Hastalık ve anormali olasılık kalibrasyonu		> 0.90	İkincil
RMSE	Karekök ortalama kare hata	Sensör okuma ve nem tahmini doğruluğu		< 1.5 birim	İkincil
MCC	Matthews Korelasyon Katsayısı	Dengesiz sınıf veri setlerinde dengeli ölçüm		> 0.75	Yardımcı

4.1 Raporlama Standardı

- Tüm metrikler 95 güven aralığı (bootstrap, n=1000) ile birlikte raporlanır.
- Makro ortalama kullanılır; sınıf ağırlıkları veri setindeki gerçek dağılımı yansıtır.
- Her sprint sonunda metrik tablosu MLflow'a kaydedilir ve trend grafiği oluşturulur.

5 Aşırı / Az Öğrenme Teşhis ve Çözüm

Validasyon sürecinde karşılaşılabilecek beş temel sorun, tanı kriterleri ve uygulanan çözümlerle birlikte aşağıda ele alınmıştır.

Belirti	Tanı Kriteri	Çözüm	Uygulama	Risk
Overfitting	Train-CV farkı > 0.10 ; std sapma yüksek	L1/L2 regülarizasyon, dropout, erken durdurma	XGBoost: max_depth sınırla, LSTM: dropout=0.3	Yüksek

Belirti	Tanı Kriteri	Çözüm	Uygulama	Risk
Underfitting	CV skoru hedefin çok altında, yüksek bias	Model karmaşıklığını artır, özellik ekle	Daha derin ağaç, polinomsal özellik türetimi	Orta
Yüksek Varyans	Foldlar arası std sapma > 0.05	Ensemble yöntemleri, veri artırma	Bagging, Random Forest ile stabilizasyon	Yüksek
Veri Sızıntısı	Train skoru anormal yüksek (> 0.99)	Özellik mühendisliğini gözden geçir	Zaman serisi split'te shuffle=False zorunlu	Kritik
Dağılım Kayması	Prod vs CV skoru > 0.08 fark	Aylık yeniden eğitim, drift monitörü	Evidently AI ile otomatik drift tespiti	Yüksek

5.1 Otomatik İzleme Pipeline'ı

- Her eğitimde train/CV fark grafiği otomatik üretilir; fark > 0.10 ise Slack alarmı tetiklenir.
- Evidently AI ile haftalık üretim drift raporu; PSI > 0.25 ise model yeniden eğitim kuyruğuna alınır.
- MLflow Model Registry: Staging aşamasındaki model ancak tüm eşikleri geçince Production'a terfi eder.

6 Validasyon Uygulama Takvimi

Beş haftalık validasyon planı aşağıdaki aktiviteleri kapsamaktadır. Her aşama bir öncekinin çıktısı üzerine inşa edilmektedir.

Aşama	Hafta	Aktivite	Sorumlu	Çıktı
1	Hafta 1	Baseline model eğitimi, K-Fold ve Stratified CV kurulumu	ML Mühendisleri	Baseline
2	Hafta 2	Time Series Split validasyonu, zaman serisi modellerinin değerlendirilmesi	ML Mühendisleri	TS Raporu
3	Hafta 3	Nested CV ile hiperparametre optimizasyonu (Optuna)	ML + AI	Opt. Modeller

Aşama	Hafta	Aktivite	Sorumlu	Çıktı
4	Hafta 4	Group K-Fold ile tarla genelleştirme testi, OOD değerlendirmesi	Tüm Ekip	Gen. Raporu
5	Hafta 5	Üretim simülasyonu, drift analizi, nihai model seçimi	DevOps + ML	Prod Modeli

7 Araç Seti ve Teknik Altyapı

Araç / Kütüphane	Versiyon	Görev	Entegrasyon
Scikit-learn	1.4+	K-Fold, Stratified, Group CV, metrik hesaplama	Python pipeline
Optuna	3.5+	Nested CV ile hiperparametre optimizasyonu (TPE)	MLflow callback
MLflow	2.10+	Deney takibi, model versiyonlama, artifact yönetimi	Django yönetim komutu
Evidently AI	0.4+	Üretim drift tespiti, veri kalitesi raporu	Celery haftalık görev
SHAP	0.44+	Fold bazında özellik önemi, açıklanabilirlik	Rapor PDF çıktısı

Bu rapor AI/ML Ekibi tarafından hazırlanmıştır. — Akıllı Tarım Yönetim Sistemi / Versiyon 1.0 / Mayıs 2025