

ÖZELLİK MÜHENDİSLİĞİ ARAŞTIRMASI

Model Performansını Artıracak Potansiyel Özelliklerin Araştırılması

Akıllı Tarım Yönetim Sistemi | AI/ML Modülü

Versiyon 1.0 | Mayıs 2025

1. Yönetici Özeti

Bu araştırma raporu, Akıllı Tarım Yönetim Sistemi'nin makine öğrenmesi modellerinin performansını artırmak amacıyla uygulanabilecek özellik mühendisliği stratejilerini kapsamlı biçimde ele almaktadır. Mevcut modellerde gözlemlenen doğruluk açıklarının kapatılması ve genelleme kapasitesinin güçlendirilmesi hedeflenmektedir. **Temel Bulgular:** Toprak nemi türev özellikleri, Fourier tabanlı mevsimsel bileşenler ve NDVI değişim hızı; model doğruluğunu ortalama %15–25 oranında artırma potansiyeline sahiptir.

2. Potansiyel Özellik Kategorileri

Model girdilerini zenginleştirmek için altı ana özellik kategorisi belirlenmiştir. Her kategori için beklenen performans katkısı ve uygulama önceliği aşağıda özetlenmektedir:

Kategori	Özellik Örnekleri	Hedef Metrik	Öncelik
Toprak & Nem	Nem oranı trendi, nem değişim hızı, kümülatif nem eksikliği	Sulama doğ. +%18	Yüksek
Hava Durumu	7 günlük yağış ortalaması, sıcaklık amplitüdü, ET_0 (buharlaşma)	Mahsul tah. +%22	Yüksek
Bitki Sağlığı	NDVI değişim hızı, klorofil indeksi, yaprak alan indeksi (LAI)	Hastalık tes. +%31	Yüksek
Toprak Kimyası	pH trendi, EC (elektriksel iletkenlik), NPK oranları	Verim tah. +%14	Orta
Operasyonel	Sulama gecikmesi, gübre uygulama süresi, iş gücü saati	Maliyet opt.	Orta
Geçmiş Veriler	Geçen yıl aynı dönem verimi, hastalık geçmişi, hava anomalileri	Model gen. +%9	Düşük

3. Özellik Mühendisliği Teknikleri

Veri setinin yapısı ve tarımsal sensör verilerinin zaman serisi niteliği gözetilerek altı temel teknik değerlendirilmiştir:

Teknik	Açıklama & Uygulama	Perf. Etkisi	Karmaşıklık
Zaman Serisi Agreg.	Kayan ortalama (7, 14, 30 gün), min/max pencere, standart sapma hesabı	+%12-18	Düşük
Polinomsal Özellikler	İkinci ve üçüncü derece nem×sıcaklık etkileşim terimleri	+%8-11	Orta
Fourier Dönüşümü	Mevsimsel döngülerin frekans bileşenlerine ayrıştırılması	+%15-20	Yüksek
Lag Özellikleri	1, 3, 7, 14 günlük gecikmeli sensör okumaları	+%10-16	Düşük
Hedef Kodlama	Arazi parçası ve mahsul türü için kategorik kodlama	+%6-9	Orta
Anomali Skoru	Isolation Forest ile toprak sensörü anomali skoru üretimi	+%13	Yüksek

3.1 Kritik Uygulama Notları

- Zaman serisi sızıntısını önlemek için tüm pencere tabanlı özellikler yalnızca geçmiş verilere bakacak şekilde hesaplanmalıdır.
- Fourier bileşenleri mevsimsel döngü uzunlukları (7, 30, 365 gün) için ayrı ayrı uygulanmalıdır.
- Polinomsal özellikler çok yüksek korelasyon ($r > 0,95$) yaratırsa Ridge/Lasso regülasyonu devreye alınmalıdır.
- Anomali skorları üretim ortamında gerçek zamanlı hesaplamaya uygun hafif modellerle oluşturulmalıdır.

4. Özellik Seçimi Yöntemleri

Üretilen yüksek sayıda özellik arasından modele en fazla katkı sağlayanları belirlemek için çok katmanlı bir seçim yaklaşımı benimsenmiştir:

Yöntem	Çalışma Prensipleri	En İyi Kullanım	Araç
Mutual Information	Hedef değişken ile özellik arasındaki bağımlılık ölçümü	Kategorik hedef	sklearn
SHAP Değerleri	Her özelliğin model çıktısına katkısını açıklar	Ağaç modelleri	shap
Recursive Feat. El.	Zayıf özellikler iteratif olarak budanır	Doğrusal modeller	sklearn
Korelasyon Analizi	Pearson/Spearman ile yüksek korelasyonlu özellikler ayıklanır	Çok değişkenli	pandas
Permutation Imp.	Özellik karıştırıldığında kayıp artışı ölçülür	Model agnostik	eli5

4.1 Önerilen Seçim Pipeline'i

1. **Korelasyon filtresi:** $r > 0,95$ olan özellik çiftlerinden biri çıkarılır.
2. **Mutual information eşiği:** En düşük %20'lik özellikler elenmeye aday kabul edilir.
3. **SHAP doğrulaması:** Kalan özellikler için küresel önem sıralaması oluşturulur.
4. **Çapraz doğrulama:** Seçilen özellik seti 5-fold CV ile nihai değerlendirmeye tabi tutulur.

5. Beklenen Performans Kazanımları

Model / Görev	Mevcut	Hedef	Artış	Risk
Sulama Kararı (Sınıf.)	F1: 0,78	F1: 0,91	+%16,7	Düşük
Mahsul Verimi Tah. (Reg.)	R ² : 0,71	R ² : 0,87	+%22,5	Orta
Hastalık Erken Tespiti	F1: 0,66	F1: 0,84	+%27,3	Orta
Su Tüketimi Tahmini	R ² : 0,74	R ² : 0,88	+%18,9	Düşük
Anomali Tespiti (Sensör)	F1: 0,59	F1: 0,79	+%33,9	Yüksek

6. Uygulama Yol Haritası

Araştırma bulgularının üretime geçirilmesi için 8 haftalık aşamalı bir uygulama planı önerilmektedir:

Aşama	Süre	Görevler	Sorumlu	Çıktı
Aşama 1	Hafta 1–2	Ham veri keşfi, eksik veri analizi, dağılım incelemeleri, korelasyon matrisi	Veri Ekibi	EDA Raporu
Aşama 2	Hafta 3–4	Zaman serisi agregasyonu, lag özellikleri, Fourier bileşenleri üretimi	ML Müh.	Özellik Seti v1
Aşama 3	Hafta 5	SHAP analizi, RFE, mutual information ile özellik seçimi	ML Müh.	Seçilmiş Özel.
Aşama 4	Hafta 6–7	A/B testi, çapraz doğrulama, model karşılaştırma deneyleri	Tüm Ekip	Performans Rap.
Aşama 5	Hafta 8	Özellik pipeline üretim ortamına entegrasyonu, monitoring	DevOps + ML	Prod Pipeline

7. Riskler ve Azaltma Stratejileri

7.1 Teknik Riskler

- **Veri sızıntısı (Data Leakage):** Zaman serisi bölmeleri mutlaka kronolojik sırayla yapılmalı; shuffle kullanılmamalıdır.
- **Yüksek boyutluluk (Curse of Dimensionality):** Özellik sayısı veri noktası sayısının karekökünü geçmemelidir.
- **Multikolinearlık:** VIF (Variance Inflation Factor) analizi ile > 10 olan özellikler düşürülmeli veya birleştirilmelidir.

7.2 Operasyonel Riskler

- **Gerçek zamanlı hesaplama yükü:** Karmaşık Fourier ve anomali özellikleri için önbellek stratejisi geliştirilmelidir.
- **Veri kalitesi:** Sensör arızaları durumunda eksik değerleri dolduran sağlam bir imputation pipeline'ı kurulmalıdır.
- **Model drift:** Aylık yeniden eğitim ve özellik dağılımı izleme mekanizması devreye alınmalıdır.

Bu rapor AI/ML Araştırma Ekibi tarafından hazırlanmıştır.
Akıllı Tarım Yönetim Sistemi | Versiyon 1.0 | Mayıs 2025